[Kelompok 12] - Final Presentation

[Nama Course : Data Science]

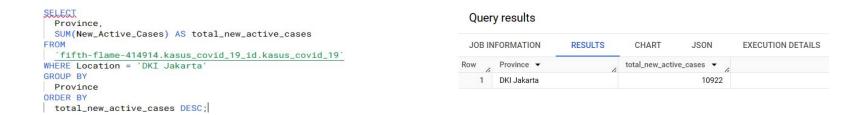
Challenge 1

Terdapat 2 hal penting yang terdapat pada challenge 1 yaitu:

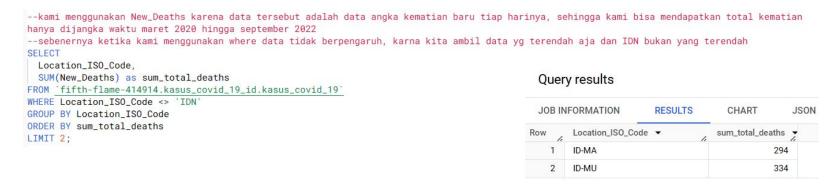
- 1) Melakukan <u>SQL Query</u>
- 2) Membuat Dashboard

1) SQL Query

1. Jumlah total kasus Covid-19 aktif yang baru di setiap provinsi lalu diurutkan berdasarkan jumlah kasus paling besar



2. Mengambil 2 location iso code yang memiliki jumlah total kematian karena Covid-19 paling sedikit



3. Data tentang tanggal-tanggal ketika rate kasus recovered di Indonesia paling tinggi beserta jumlah ratenya tinggi

```
--Kita memutuskan menggunakan LIMIT untuk menentukan nilai paling maksimal
SELECT
Date,
MAX(Case_Recovered_Rate) AS Highest_Recovery_Rate
FROM
__imy-project-challenge-binar.dataset_covid19indo.covidi
GROUP BY
Date
ORDER BY
Highest_Recovery_Rate DESC
LIMIT
1;
```

4. Total case fatality rate dari masing-masing location iso code yang diurutkan dari data yang paling rendah

```
SELECT
Location_ISO_Code,
SUM(New_Deaths) / SUM(New_Cases) as total_case_fatality_rate,
FROM `fifth-flame-414914.kasus_covid_19_id.kasus_covid_19`
GROUP BY Location_ISO_Code
ORDER BY total_case_fatality_rate;
```

Query results

JOB INFORMATION		RESULTS CHAR		Т	,	
Row /	Date ▼	1.	Highest_Rec	overy_Rate	•	1.
1	2020-03-06				111.0	

Query results

JOB IN	IFORMATION R	ESULTS	CHART	JS0
Row	Location_ISO_Code ▼	6	total_case_fatality	_ra
1	ID-BT		0.008820666417	
2	ID-JK		0.010968697476	9
3	ID-PA		0.011596931520	
4	ID-PB		0.011936586882	
5	ID-JB		0.013578068569	
6	ID-MA		0.015691716481	
7	ID-NT		0.016173277551	
8	ID-SN		0.017197945935	
9	ID-KB		0.017224296928	
10	ID-BE		0.017893257464	
11	ID-KU		0.018935640839	
12	ID-SU		0.020696687774	
13	ID-SG		0.022146109835	
14	ID-SB		0.022658639143	

4. Total case recovered rate dari masing-masing location iso code yang diurutkan dari data yang paling rendah

```
SELECT
Location_ISO_Code,
SUM(New_Recovered) / SUM(New_Cases) as total_case_recovered_rate
FROM __ifith-flame-414914.kasus_covid_19_id.kasus_covid_19_i
GROUP BY Location_ISO_Code
ORDER BY total_case_recovered_rate;
```

5. Data tentang tanggal-tanggal saat total kasus Covid-19 mulai menyentuh angka 30.000-an (30.001)

Query results

JOB IN	FORMATION	RESULTS	CHART	JS
Row	Location_ISO_Co	ode ▼	total_case_reco	vered
1	ID-LA		0.94155130158	33
2	ID-JT		0.94515633814	11
3	ID-JI		0.94535969704	11
4	ID-AC		0.94718197919	9
5	ID-SS		0.95512056254	14
6	ID-GO		0.96287004515	8
7	ID-SA		0.96632556376	7
8	ID-KS		0.96872284969	95
9	ID-BA		0.96880076244	18
10	ID-RI		0.96936743357	72
11	ID-KT		0.96937320713	88
12	ID-ST		0.97016317779	93
10	ID VO		0.07050041500	00

Query results

JOB IN	IFORMATION	RESULTS	CHA	F
Row	Date ▼	Total_Case	es 🔻	
1	2020-06-06		30514	
2	2020-06-07		31186	
3	2020-06-08		32033	
4	2020-06-09		33075	
5	2020-06-10		34316	
6	2020-06-11		35295	
7	2020-06-12		36406	
8	2020-06-13		37420	

6. Jumlah data yang tercatat ketika kasus Covid-19 lebih dari atau sama dengan 30.000

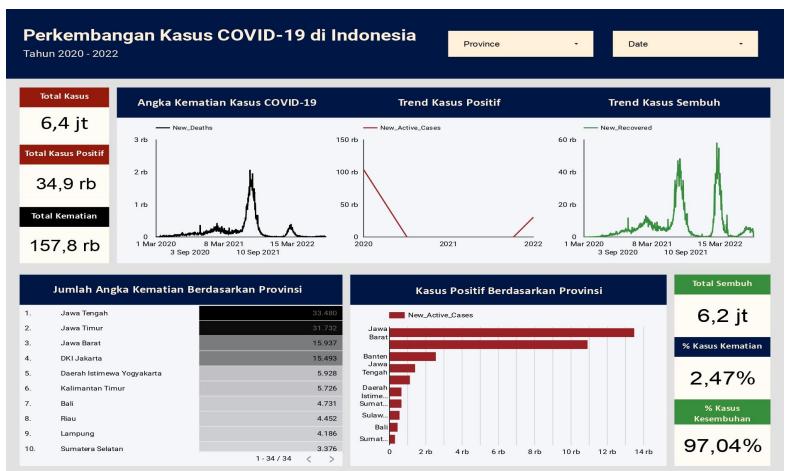
```
--Jumlah data menggunakan New_Cases untuk mendapatkan kasus covid-19 tiap harinya lebih dari atau sama dengan 30.000 SELECT

| COUNT(New_Cases) as total_recorded_cases |
FROM _fifth-flame-414914.kasus_covid_19_id.kasus_covid_19_ |
WHERE New_Cases >= 30000;
```

Query results

JOB IN	FORMATION	RESULTS		
Row	total_recorded_c	ases 🔻		
1		61		

2) Dashboard



2) Dashboard

Pada seluruh dashboard kami menggunakan data:

- New Deaths
- New_Active_Cases
- New_Recovered

Dan dua rumus yaitu:

- SUM(New_Deaths) / SUM(New_Cases) = %Kasus Kematian
- SUM(New_Recovered) / SUM(New_Cases) =
 %Kasus Kesembuhan

Penjelasan Lebih Lanjut:

- Pada grafik "Trend Kasus Positif" pada Tahun 2021 grafik menunjukkan penurunan hingga dibawah 0
- Kami melakukan pemeriksaan data menggunakan Query:

```
SELECT
New_Active_Cases, Date
FROM
`fifth-flame-414914.kasus_covid_19_id.kasus_covid_19`
where Date >= '2021-01-01' and Date < '2022-01-01'
```

Hal ini disebabkan :

Terdapat data negatif mulai dari puluhan hingga ribuan sehingga menyebabkan grafik pada tahun 2021 turun

hingga >0

Row /	New_Active_Cases/	Date ▼
38	-142	2021-02-07
39	-5003	2021-02-08
40	-1937	2021-02-09
41	-935	2021-02-10
42	-1924	2021-02-11
43	-1406	2021-02-12
44	-3355	2021-02-13
45	-2719	2021-02-14
46	-514	2021-02-15

Pada seluruh dashboard kami menggunakan data:

- New_Deaths
- New_Active_Cases
- New_Recovered Dan dua rumus yaitu :
- SUM(New Deaths) / SUM(New Cases) = %Kasus Kematian
- SUM(New_Recovered) / SUM(New_Cases) = %Kasus Kesembuhan

Penjelasan Lebih Lanjut:

- Pada grafik "Trend Kasus Positif" pada Tahun 2021 grafik menunjukkan penurunan hingga dibawah 0
- Kami melakukan pemeriksaan data menggunakan

Query:

SELECT

New Active Cases, Date

FROM

`fifth-flame-414914.kasus covid 19 id.kasus covid 19`

where Date >= '2021-01-01' and Date < '2022-01-01'

Hal ini disebabkan :

Terdapat data negatif mulai dari puluhan hingga ribuan sehingga menyebabkan grafik pada tahun 2021 turun hingga >0

Row /	New_Active_Cases/	Date ▼
38	-142	2021-02-07
39	-5003	2021-02-08
40	-1937	2021-02-09
41	-935	2021-02-10
42	-1924	2021-02-11
43	-1406	2021-02-12
44	-3355	2021-02-13
45	-2719	2021-02-14
46	-514	2021-02-15

Challenge 2

FILE PENGUMPULAN:

Berikut file hasil analisis:

Link Google Colabs

Tahapan Machine Learning

Pada kesempatan kali ini kami akan melakukan studi kasus untuk memprediksi customer churn di perusahaan telekomunikasi.

Berikut dataset yang digunakan:

<u>Data Train</u>

Data Test

A. Import Data

1. Upload File

from google.colab import files uploaded = files.upload()

2. Baca Dataset Train

df = pd.read_csv('/content/Data Train (2).csv')

3. Import Library Yang Dibutuhkan

```
#import library
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
from scipy import stats
#import library scikit-learn untuk proses statistika san meachine learning
from sklearn.preprocessing import OneHotEncoder
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import MinMaxScaler
from sklearn.model selection import train test split
from sklearn.decomposition import PCA
from sklearn.discriminant analysis import LinearDiscriminantAnalysis
from sklearn import model selection
from sklearn.linear model import LogisticRegression
from sklearn.metrics import roc auc score
from sklearn.metrics import f1 score
from sklearn.metrics import log loss
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy score
from sklearn.datasets import load digits
from sklearn.feature selection import SelectKBest, chi2
from sklearn.tree import DecisionTreeClassifier
from sklearn.model selection import GridSearchCV
```

4. Melihat Informasi dari dataset

df.info()

```
RangeIndex: 4250 entries, 0 to 4249
Data columns (total 20 columns):
                                    Non-Null Count Dtype
     Column
     state
                                    4250 non-null
                                                    object
     account length
                                    4250 non-null
                                                    int64
     area code
                                    4250 non-null
                                                    object
     international plan
                                    4250 non-null
                                                    object
     voice mail plan
                                    4250 non-null
                                                    object
     number vmail messages
                                    4250 non-null
                                                    int64
     total day minutes
                                    4250 non-null
                                                    float64
     total day calls
                                                    int64
                                    4250 non-null
     total day charge
                                    4250 non-null
                                                    float64
     total eve minutes
                                    4250 non-null
                                                    float64
    total eve calls
                                    4250 non-null
                                                    int64
    total eve charge
                                    4250 non-null
                                                    float64
    total night minutes
                                                    float64
                                    4250 non-null
    total night calls
                                    4250 non-null
                                                    int64
14 total night charge
                                    4250 non-null
                                                    float64
    total intl minutes
                                    4250 non-null
                                                    float64
    total intl calls
                                    4250 non-null
                                                    int64
17 total intl charge
                                    4250 non-null
                                                    float64
    number customer service calls 4250 non-null
                                                    int64
                                    4250 non-null
                                                    object
dtypes: float64(8), int64(7), object(5)
memory usage: 664.2+ KB
```

5. Melihat 5 Data teratas (dari sini kita sudah bisa melihat variabel dependentnya adalah 'churn'

<class 'pandas.core.frame.DataFrame'>

df.head()
#churn = dependent

	state	account_length	area_code	international_plan	voice_mail_plan	number_vmail_messages	total_day_minutes	total_day_calls	total_day_charge	total_eve_minutes	total_eve_c
0	ОН	107	area_code_415	no	yes	26	161.6	123	27.47	195.5	
1	NJ	137	area_code_415	no	no	0	243.4	114	41.38	121.2	
2	ОН	84	area_code_408	yes	no	0	299.4	71	50.90	61.9	
3	OK	75	area_code_415	yes	no	0	166.7	113	28.34	148.3	
4	MA	121	area_code_510	no	yes	24	218.2	88	37.09	348.5	

B. Data Cleaning

- 1. Missing Value
- 2. Duplicated Value

```
df.isna().sum()
# Data bersih tidak memiliki null
# Data tidak memerlukan langkah fillna

df.duplicated().sum()
# data bersih tanpa duplicate
```

df.nunique().sort values()

C. Data Prepocessing

1. Kategorisasi Data

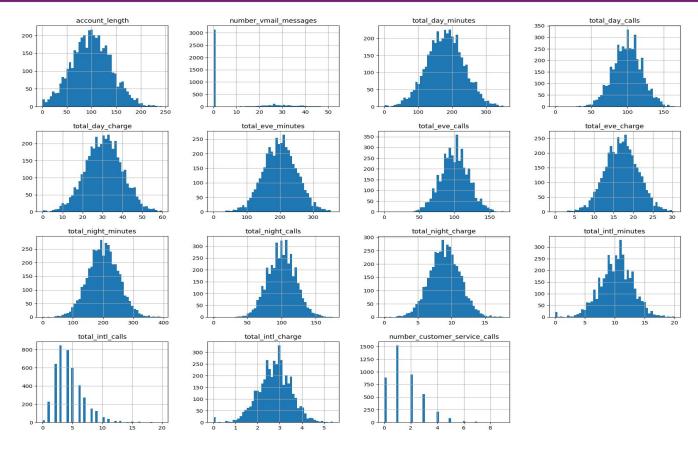
categorical col = ['state', 'area code', 'international plan', 'voice mail plan', 'churn']

- 2. Unik Value
- 3. Cek Outlier

```
df[numeric col].hist(bins=50, figsize=(20,15))
```

```
#Boxplot untuk mengindentifikasi outliers
fig = plt.figure(figsize=[32,24])
fig.suptitle('BOXPLOT OF NUMERICAL DATA', fontsize=25, fontweight='bold')
fig.subplots_adjust(top=0.92);
fig.subplots_adjust(hspace=0.5, wspace=0.4);
for i ,column in enumerate(numeric_col):
    ax1 = fig.add_subplot(6,3, i+1);
    ax1 = sns.boxplot(data = df, x=column);

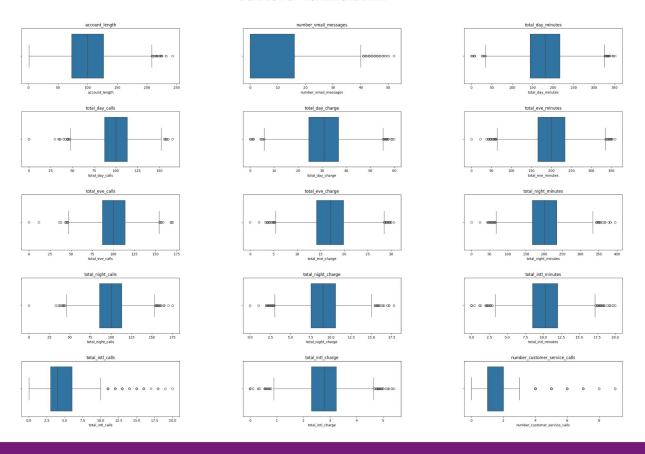
ax1.set_title(f'{column}')
    ax1.set_xlabel(f'{column}')
```



semua terdistribusi normal kecuali total_intl_calls, number_customer_service_calls, dan number_vmail_messages

Kita juga menggunakan boxplot untuk mengidentifikasi outlier

BOXPLOT OF NUMERICAL DATA



4. Mengatasi Otliers

ax1.set xlabel(f'{col}')

```
#Penangan jika numerical data terdapat Outliers menggunakan IQR
                                  # Dan menggunakan capping (mengubah nilai outliers dengan nilai upper / lower limit)
                                  dict = {}
                                  for col in numeric_col:
                                     Q1 = df[col].quantile(0.25)
                                     Q3 = df[col].quantile(0.75)
                                     IQR = Q3 - Q1
                                     upper limit = Q1 + 1.5 * IQR
                                     lower limit = Q3 - 1.5 * IQR
                                     dict['upper_limit' + col] = upper_limit
                                     dict['lower limit' + col] = lower limit
                                  for col in numeric col:
                                     df[col] = np.where(
                                         df[col] > dict['upper limit' + col],
                                        dict['upper limit' + col],
                                         np.where(
                                            df[col] < dict['lower limit' + col],</pre>
                                            dict['lower limit' + col],
                                            df[col]
#Boxplot setelah cleaning outlier
fig = plt.figure(figsize=[32,24])
fig.suptitle('DATA BLOXPLOT AFTER OULIERS CLEANING', fontsize=18, fontweight='bold')
fig.subplots adjust(top=0.92);
fig.subplots adjust(hspace=0.5, wspace=0.4);
for i ,col in enumerate(numeric col):
     ax1 = fig.add subplot(6,3, i+1);
     ax1 = sns.boxplot(data = df, x=col);
     ax1.set title(f'{col}')
```

Boxplot Setelah Outliers ditangani

DATA BLOXPLOT AFTER OULIERS CLEANING



- Measure Of Central Tendency df.describe()
- Melihat Unik Value df.nunique().sort_values()
- 3. Analisa Multivariat

```
plt.figure(figsize=(30,15))
corr_matrix = df.corr()

sns.heatmap(corr_matrix, annot=True, cmap='viridis')
plt.show()
```

4. Analisa Univariat

Presentase Churn Kostumer

```
# Melihat berapa banyak churn dilakukan oleh pelanggan
df.groupby('churn').size().plot(kind='pie', autopct = '%.1f%%', radius=1)
```

Demografi

```
# area code, international plan, voice mail plan yang melakukan churn
fig, axs = plt.subplots(1, 3, figsize=(14,5))
# Count plot AREA CODE
sns.countplot(x='area code', hue='churn', data=df, ax=axs[0])
axs[0].set title('Churn Area Code')
# Count plot INTERNATIONAL PLAN
sns.countplot(x='international plan', hue='churn', data=df, ax=axs[1])
axs[1].set title('Churn International Plan')
# Count plot for VOICE MAIL PLAN
sns.countplot(x='voice mail plan', hue='churn', data=df, ax=axs[2])
axs[2].set title('Churn Voice Mail Plan')
plt.tight_layout()
plt.show()
```

Hubungan Numerical Data dengan Churn

Features

```
total_durasi= df['total_day_minutes'] + df['total_eve_minutes'] + df['total_night_minutes']
total_charge = df['total_day_charge'] + df['total_eve_charge'] + df['total_night_charge']
total_calls = df['total_day_calls'] + df['total_eve_calls'] + df['total_night_calls']

df['total_durasi'] = total_durasi
df['total_charge'] = total_charge
df['total_calls'] = total_calls
```

Q1 : Bagaimana pengaruh lama panggilan terhadap harga

A1: Positif Correlation

```
[41] plt.figure(figsize=(5,5))
    plt.scatter(x='total_durasi',y='total_charge',data=df, color='yellow')
    plt.xlabel('Durasi')
    plt.ylabel('Price')

Text(0, 0.5, 'Price')
```

Insight

dapat dilakukan promo panggilan, atau gratis panggilan berdasarkan durasi

```
[42] sns.histplot(df.total_durasi,bins=10)

Q2:Pengaruh jumlah panggilan terhadap harga
A2:No Correlation

[43] plt.figure(figsize=(5,5))
    plt.scatter(x='total_calls',y='total_charge',data=df, color='yellow')
    plt.xlabel('Panggilan')
    plt.ylabel('Price')

    Text(0, 0.5, 'Price')

[44] sns.histplot(df.total_calls,bins=10)
```

Total calls tidak memiliki korelasi terhadap Total_charge. Sehingga penentuan total tagihan tidak berdasarkan jumlah panggilan melainkan jumlah durasi, mayoritas pelanggan melakukan panggilan sebanyak kurang lebih 270 hingga 350 setiap periode langganan.

E. Data Preprocessing

1. Features and mapping

```
[46] # Dropping column yang tidak digunakan
   df.drop(columns=['account length', 'state', 'total day minutes', 'total day charge', 'total eve minutes', 'total eve charge', 'total night minutes',
                     'total night charge', 'total intl minutes', 'total day calls', 'total eve calls', 'total night calls', 'total intl calls'], inplace=True)
#Mengganti string 'yes' 'no'menjadi dummy
df['international plan'] = df['international plan'].map({'yes': 1, 'no': 0})
df['voice mail plan'] = df['voice mail plan'].map({'ves': 1, 'no': 0})
df['area code'] = df['area code'].map({'area code 415': 1, 'area code 408':2, 'area code 510': 3})
df['churn'] = df['churn'].map({'yes': 1, 'no': 0})
 sns.heatmap(df.corr())
#Melakukan treatment terhadap multikolinieritas
df.drop(columns=['number vmail messages'], inplace=True)
[50] sns.heatmap(df.corr())
[51] df.hist(bins=50, figsize=(20,15))
```

2. Data Modelling

```
[52] #Drop Target Variable
    X = df.drop('churn' , 1 )
    y = df['churn']

[53] #Train-test Split
    #Kami menggunakan test size 20%, dan random_state pada d123
    # Split data ke training(80%) dan testing(2%).
    from sklearn.model_selection import train_test_split
    X_train,X_test,y_train,y_test = train_test_split(X, y, test_size = 0.2, random_state =0)
```

Model yang kami gunakan:

- Logistic Regression
- Decision Tree
- Random Forest

Feature Scaling

```
[60] sc_X = StandardScaler()
    X_train = sc_X.fit_transform(X_train)
    X_test = sc_X.transform(X_test)
```

Model Logistic Regression

```
[61] #Feature Scaling
    from sklearn.preprocessing import StandardScaler
    from sklearn.linear model import LogisticRegression
    #Fitting Logistic Regression di Training Set
    logreg = LogisticRegression(random state = 0)
    logreg.fit(X train, y train)
#Predicting Test Result
y pred = logreg.predict(X test)
y pred
[63] # Evaluating Model
     from sklearn.metrics import confusion matrix
     conmat = confusion matrix(y test, y pred)
     conmat
     array([[726, 9],
            [100, 15]])
```

```
#Accuracy dan Missclassification Rate
accuracy1 = (726 + 15) / 100
print('Accuracy rate dari model Logistic Regression adalah: ' + str(accuracy1))
missclass1 = (9 + 100) / 100
print('Missclassification rate dari model Logistic Regression adalah: ' + str(missclass1))
```

Accuracy rate dari model Logistic Regression adalah: 7.41 Missclassification rate dari model Logistic Regression adalah: 1.09

Model Decision Tree

```
dtc = DecisionTreeClassifier()
dtc.fit(X_train, y_train)
```

```
[66] # Predict Model
    predictions_tree = dtc.predict(X_test)
    predictions_tree
```

Evaluasi Model
from sklearn.metrics import classification_report, confusion_matrix
print(classification_report(y_test, predictions_tree))

	precision	recall	f1-score	support
0	0.94	0.92	0.93	735
1	0.55	0.61	0.58	115
accuracy			0.88	850
macro avg	0.74	0.77	0.75	850
weighted avg	0.89	0.88	0.88	850

```
print(confusion_matrix(y_test, predictions_tree))

[[678 57]
  [ 46 69]]

#Accuracy dan Missclassification Rate
accuracy2 = (675 + 69) / 100
print('Accuracy rate dari model Decisions Tree adalah: ' + str(accuracy2))
missclass2 = (60 + 46) / 100
print('Missclassification rate dari model Decisions Tree adalah: ' + str(missclass2))

Accuracy rate dari model Decisions Tree adalah: 7.44
```

Missclassification rate dari model Decisions Tree adalah: 1.06

Model Random Forests

```
from sklearn.ensemble import RandomForestClassifier
rforest = RandomForestClassifier(n estimators=100)
rforest.fit(X train, y train)
rforest pred = rforest.predict(X test)
[71] print(classification_report(y test, rforest_pred))
                  precision
                              recall f1-score
                                                support
                      0.94
                                0.98
                                         0.96
                                                   735
                                0.58
                                         0.68
                      0.82
                                                   115
                                         0.93
                                                   850
         accuracy
                                         0.82
        macro avg
                      0.88
                                0.78
                                                   850
     weighted avg
                      0.92
                                0.93
                                         0.92
                                                   850
[72] print(confusion_matrix(y_test, rforest_pred))
     [[720 15]
      48
           67]]
```

```
[73] #Accuracy dan Missclassification Rate
    accuracy3 = (722 + 68) / 100
    print('Accuracy rate dari model Random Forest adalah: ' + str(accuracy3))
    missclass3 = (13 + 47) / 100
    print('Missclassification rate dari model Random Forest adalah: ' + str(missclass3))
```

Accuracy rate dari model Random Forest adalah: 7.9 Missclassification rate dari model Random Forest adalah: 0.6

Kesimpulan

Random Forest memiliki accuracy paling tinggi

```
[78] print('----Logistic Regression----')
     print('Accuracy rate dari model Logistic Regression adalah: ' + str(accuracy1))
     print('Missclassification rate dari model Logistic Regression adalah: ' + str(missclass1))
     print('----Decisions Tree----')
     print('Accuracy rate dari model Decisions Tree adalah: ' + str(accuracy2))
     print('Missclassification rate dari model Decisions Tree adalah: ' + str(missclass2))
     print('----Random Forest----')
     print('Accuracy rate dari model Random Forest adalah: ' + str(accuracy3))
     print('Missclassification rate dari model Random Forest adalah: ' + str(missclass3))
     print('----KNN----')
     print('Accuracy rate dari model KNN adalah: ' + str(accuracy4))
     print('Missclassification rate dari model KNN adalah: ' + str(missclass4))
     ----Logistic Regression----
     Accuracy rate dari model Logistic Regression adalah: 7.41
     Missclassification rate dari model Logistic Regression adalah: 1.09
     ----Decisions Tree----
     Accuracy rate dari model Decisions Tree adalah: 7.44
     Missclassification rate dari model Decisions Tree adalah: 1.06
     ----Random Forest----
     Accuracy rate dari model Random Forest adalah: 7.9
     Missclassification rate dari model Random Forest adalah: 0.6
     ----KNN----
     Accuracy rate dari model KNN adalah: 7.66
     Missclassification rate dari model KNN adalah: 0.84
```

Simpan model kemudian upload data test

```
[79] import pickle
    rforest = RandomForestClassifier(n_estimators=100)
    rforest = rforest.fit(X_train, y_train)
    pickle.dump(rforest, open('forest.pkl', 'wb'))

[80] from google.colab import files
    uploaded = files.upload()

[82] df = pd.read_csv('/content/Data Test.csv')
[83] df.head()
```

```
[84] #Membuat fungsi preprocessing untuk label encoding data yang baru masuk
     def Preprocess(data):
        # Assign new variable
        total durasi= df['total day minutes'] + df['total eve minutes'] + df['total night minutes']
        total charge = df['total day charge'] + df['total eve charge'] + df['total night charge']
        total calls = df['total day calls'] + df['total eve calls'] + df['total night calls']
        df['total durasi'] = total durasi
        df['total charge'] = total charge
        df['total calls'] = total calls
        #Mengganti string 'yes' 'no'menjadi dummy
        df['international plan'] = df['international plan'].map({'yes': 1, 'no': 0})
        df['voice mail plan'] = df['voice mail plan'].map({'yes': 1, 'no': 0})
        df['area code'] = df['area code'].map({'area code 415': 1, 'area code 408':2, 'area code 510': 3})
        # Dropping column yang tidak digunakan
        df.drop(columns=['account length', 'state', 'total day minutes', 'total day charge', 'total eve minutes', 'total eve charge', 'total night minutes',
                            'total night charge', 'total intl minutes', 'total day calls', 'total eve calls', 'total night calls', 'total intl calls'], inplace=True)
        #Melakukan treatment terhadap multikolinieritas
        df.drop(columns=['number vmail messages'], inplace=True)
        #Variable X
        X = ['area_code', 'international_plan', 'voice_mail_plan', 'total_intl_charge', 'number_customer_service_calls','total_durasi','total_charge','total_calls']
        return data[X]
```

	area_code	international_plan	voice_mail_plan	total_intl_charge	number_customer_service_calls	total_durasi	total_charge	total_calls
0	1	0	1	2.70	1	707.2	72.86	300
1	3	1	0	1.70	0	647.9	65.91	317
2	1	0	0	3.54	4	630.9	55.77	245
3	3	0	0	2.19	3	538.5	56.80	346
4	1	0	0	4.19	3	652.1	55.96	303
		(box)		3440	1000	300		
745	1	0	0	3.05	0	548.4	48.66	307
746	2	0	0	3.32	3	689.5	63.99	314
747	1	0	0	3.97	3	654.6	62.75	276
748	1	0	0	3.67	1	525.8	48.15	314
749	3	0	0	2.30	0	584.9	56.79	248

750 rows × 8 columns





```
[86] #Memanggil Model dan melakukan prediksi
   rforest model = pickle.load(open('/content/forest.pkl', 'rb'))
   r forest test predictions = rforest model.predict(df test)
[87] print("Predictions:")
   print(r forest test predictions)
   Predictions:
   11110111001001001111111111001111111100111
   1 1 1 0 1 1 1 0 1 0 1 0 0 1 0 1 1 0 0 1 0 1 1 0 1 0 0 1 1 1 1 0 1 0 1 1 1 0 0 0 1
   10011001110101110001010011001101101101
   1 1 1 0 1 1 1 1 0 1 0 0 1 1 1 1 1 1 0 0 0 1 1 0 1 0 1 1 1 1 1 1 0 1 1 0 0 0 1
   0 1 1 1 1 0 1 1 0 0 1 1 1 1 1 1 0 1 1 1 1 1 1 1 1 1 1 0 1 1 0 0 0 1 0 1 0 1 1 1 1 1
   1 1 1 0 1 1 1 0 1 1 0 0 1 0 1 0 1 0 1 1 0 1 0 0 0 0 1 1 0 1 1 1 1 1 1 1 0 0 0 1
   10011101010111111111111110101101101101
   1 1 1 1 1 1 0 1 1 1 1 1 1 1 0 0 0 1 1 1 1 1 0 0 0 1 1 0 0 1 1 0 0 1 1 1 1 1 1 1 1 1 1
   1101111111
```

Interpretasi:

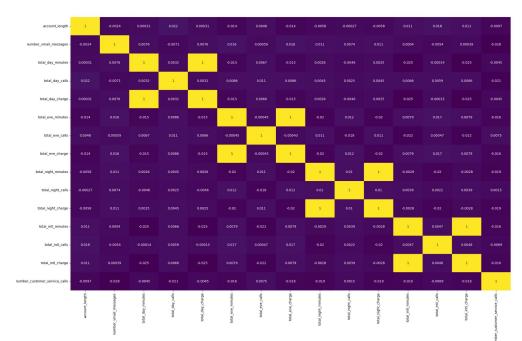
1. Analisa Multivariat

Treatment:

- melakukan kombinasi variable yang terindikasi multikolinieritas
 - total_charge = total_day_charge + total_eve_charge + total_night_charge
 - total_minutes = total_day_minutes+total_eve_minutes+ total_night_minutes
- 2. mengeliminasi salah satu variable yang memiliki korelasi tinggi tersebut

total_intl_minutes & intl_charge,

karena dalam data kami mengamati pengaruh international plan terhadap churn maka, kami memberi treatment pada multikolinieritas ini dengan drop total total_intl_minutes



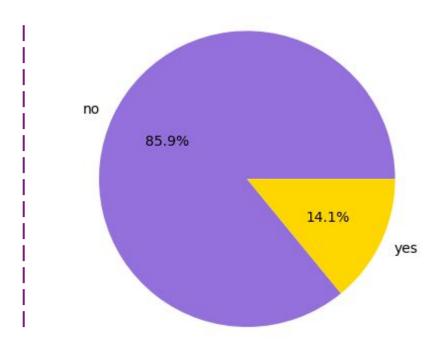
Terdapat multikolinearitas:

- total_day_minutes and total_day_charge
- 2. total_eve_minutes and total_eve_charge
- total_night_minutes and total_night_charge
- 4. total intl minutes and total intl charge

2. Analisa Univariat

Problem Business

terdapat 14.1% kosumen yang melakukan churn, beralih menggunakan produk lain, maka perlu dilakukan peningkatan peforma pelayanan kepada konsumen berdasarkan hasil analisa yang menargetkan konsumen untuk tetap menggunakan layanan perusahaan ini (loyalitas)



2. Analisa Univariat

Pelanggan paling banyak berasal dari area code 415, diikuti oleh area code 408 dan 510

Mayoritas pelanggan tidak menggunakan layanan international, dan tidak menggunakan voice mail

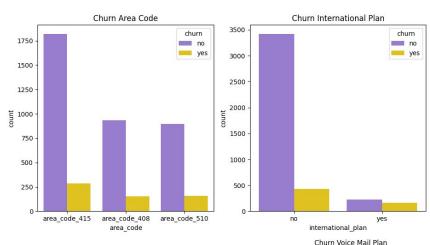
Insight:

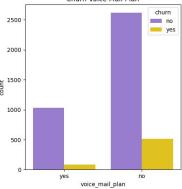
- Area 415 memiliki tingkat churn paling tinggi
- Pelanggan yang tidak melakukan international plan lebih cenderung mempertahankan untuk berlangganan dibanding pelanggan yang melakukan langganan international

PERLU PENINGKATAN DI INTERNATIONAL PLAN

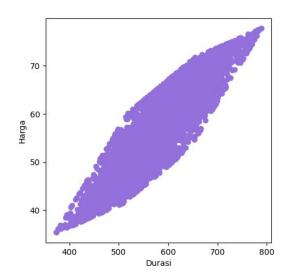
 Pelanggan yang tidak melakukan langganan voice mail cenderung melakukan churn dibandingkan yang melakukan langganan voice mail

PERLU PROMOSI TENTANG HARGA VOICE MAIL YANG TERJANGKAU, SEHINGGA PELANGGAN YANG BELUM MELAKUKAN LANGGANAN VOICE MAIL DAPAT MERASAKAN LAYANAN INI

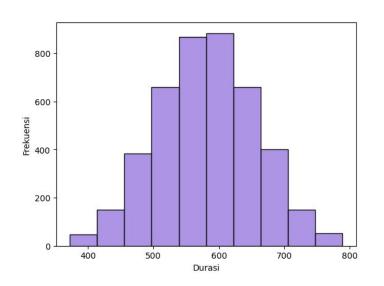




Q1: Bagaimana pengaruh lama panggilan terhadap harga



Total_durasi dan **Total Charge** memiliki korelasi positif, dimana semakin meningkat total panggilan harga tagihan akan semakin tinggi

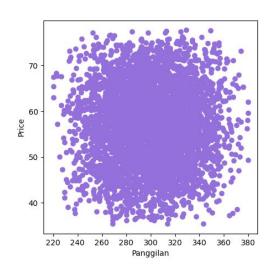


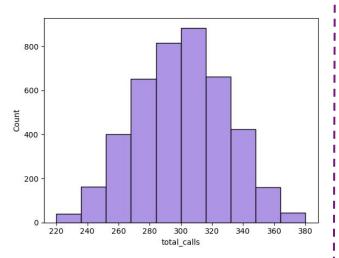
Dapat dilihat bahwa mayoritas dari pelanggan melakukan total durasi panggilan selama 500 hingga kurang lebih 650 menit dan mendapatkan charge sebesar 50 hingga 65.

Insight:

dapat dilakukan promo panggilan, atau gratis panggilan berdasarkan durasi

Q2: Pengaruh jumlah panggilan terhadap harga



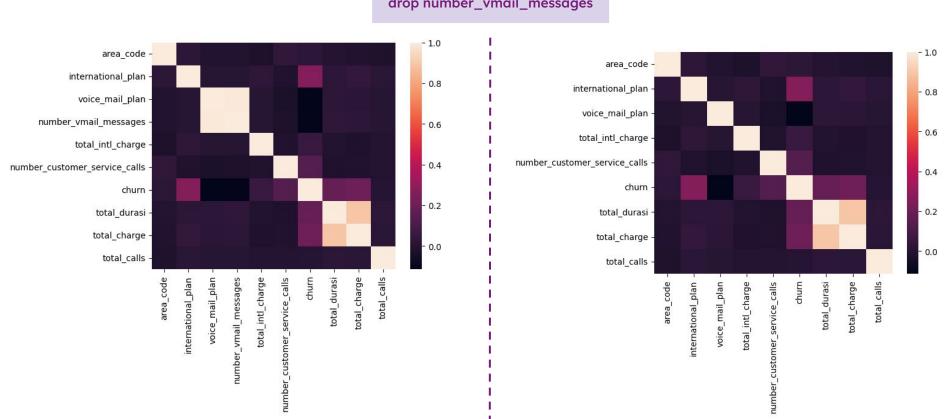


Total calls tidak memiliki korelasi terhadap Total_charge. Sehingga penentuan total tagihan tidak berdasarkan jumlah panggilan melainkan jumlah durasi, mayoritas pelanggan melakukan panggilan sebanyak kurang lebih 270 hingga 350 setiap periode langganan.

Data Pre-Processing

Pengecekan Corr()

drop number_vmail_messages



Hasil Model

Random Forest

1.Logistic Regression

Accuracy rate dari model Logistic Regression adalah: (87%)

2. Decisions Tree

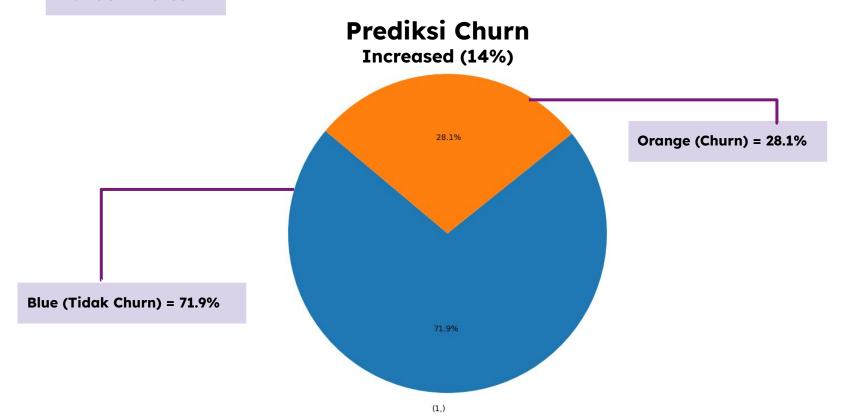
Accuracy rate dari model Decisions Tree adalah: (87%)

3. Random Forest

Accuracy rate dari model Random Forest adalah: (93%)

Hasil Model

Random Forest



Business Insights:

Business Insight



1. Harga

- Pemberian potongan harga dan gratis panggilan
 - kepada konsumen loyal sebagai bentuk penghargaan. Mengingat tidak banyak konsumen yang melakukan churn, maka **loyalitas konsumen menjadi prioritas**.
- pemberian promo khusus dan reward untuk daerah 415, untuk menekan angka churn, dengan meningkatkan loyalitas kepada brand



2. Loyalitas

- Meningkatkan tawaran layanan program langganan international
- Melakukan promosi harga voice mail / tawaran layanan voice mail gratis untuk periode tertentu, agar konsumen mau mencoba layanan ini

Mengingat konsumen yang menggunakan layanan voice mail dan international memiliki total churn lebih rendah, menandakan bahwa konsumen memiliki kepuasan terhadap layanan ini dan menjadi salah satu faktor konsumen memutuskan untuk tetap loyal pada brand



3. Model

Berdasarkan hasil analisa model, maka dapat disimpulkan bahwa model yang paling mampu menghasilkan hasil paling akurat diantara tiga model yang diuji adalah **model Random Forest**